Зимняя школа ННГУ по оптимизации алгоритмов компьютерного зрения 2022

SIMD и автовекторизация

Екатерина Антакова,
старший инженер в Интел

Содержание

Цели лекции

- Узнать о векторизации, чтобы её использовать
- Научиться проверять наличие векторизации
- Научиться включать автовекторизацию и улучшать её

“The ability to perform Vectorization has become a key skill”

—Andrew Ng

From “Neural Networks and Deep Learning” course

Часть 1. Введение / SIMD = Single Instruction Multiple Data

- SIMD – одновременное исполнение одной инструкции на нескольких элементах данных с экономией времени исполнения и мощности
- Примеры инструкций:
  - MMX, SSE, SSE2, SSE3…, AVX, AVX-2, AVX-512
- SIMD реализовано через специальные регистры и векторные инструкции

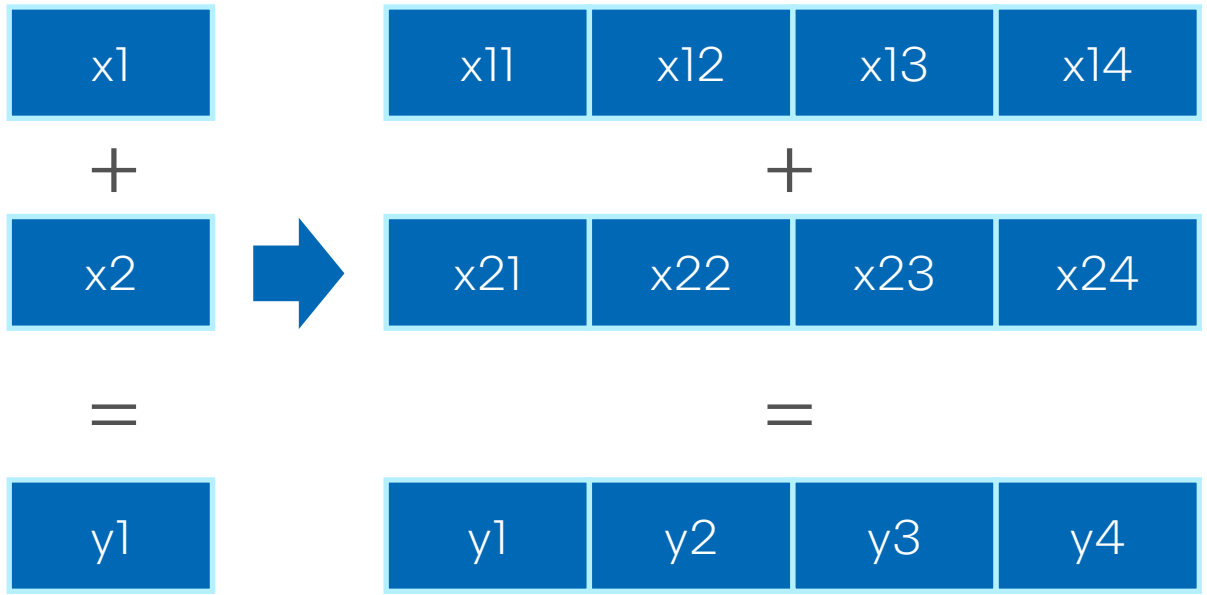

SIMD и векторизация – синонимы в этой лекции

Часть 1. Введение. Преимущества и недостатки векторизации

+ Ускорение - обработка многих элементов за один процессорный такт
  - Хорошо ускоряется код, ограниченный вычислениями (compute-bound)
+ Векторизация эффективно обрабатывает короткие типы данных
  - Чем меньше тип данных (Int32 -> Int16 -> Int8), тем больше ускорение

- Алгоритмы, ограниченные пропускной способностью диска (I/O) или памяти, мало выиграют от векторизации
- Часто нужны доработка кода и расположения данных, подсказки компилятору для векторизации

Часть 2. Инструкции / Векторные расширения инструкций

- Векторные расширения присутствуют в наборах команд процессоров различных производителей и архитектур
  - Intel: MMX – SSE – SSE2 – SSE3 – SSE4 – AVX – AVX-512
  - AMD: 3DNow!
  - ARM: NEON
- Далее рассмотрим некоторые векторные инструкции
- Узнаем, как соотносится расчетный код на C/C++ и машинный код, порождаемый компилятором

Часть 2. Инструкции / Основные типы операций

- *Арифметические операции*: сложение, вычитание, умножение, деление, FMA (Fused Multiply-Add) для вычислений с плавающей запятой
- *Операции преобразования типов*: повышающие и понижающие преобразования
- *Логические операции*: векторные сравнения, поиск минимума и максимума и т.д.
- *Операции доступа к данным* (загрузка/выгрузка память/регистр; scatter/gather, предвыборка, streaming stores). Могут применяться маскирование, shuffle

Скалярная	Векторная
ADD	VADDPD
DIV	VDIVPS
CBW	CVTPS2PD
CMP	PCMPEQW
XOR	XORPD
MOV	MOVDQA

Часть 2. Инструкции / Регистры

Векторное расширение	Название регистров	Ширина регистра	Сколько float-чисел обрабатывает одновременно
SSE	xmm0 to xmm15	128 бит	4
AVX2	ymm0 to ymm15	256 бит	8
AVX512	zmm0 to zmm31	512 бит	16

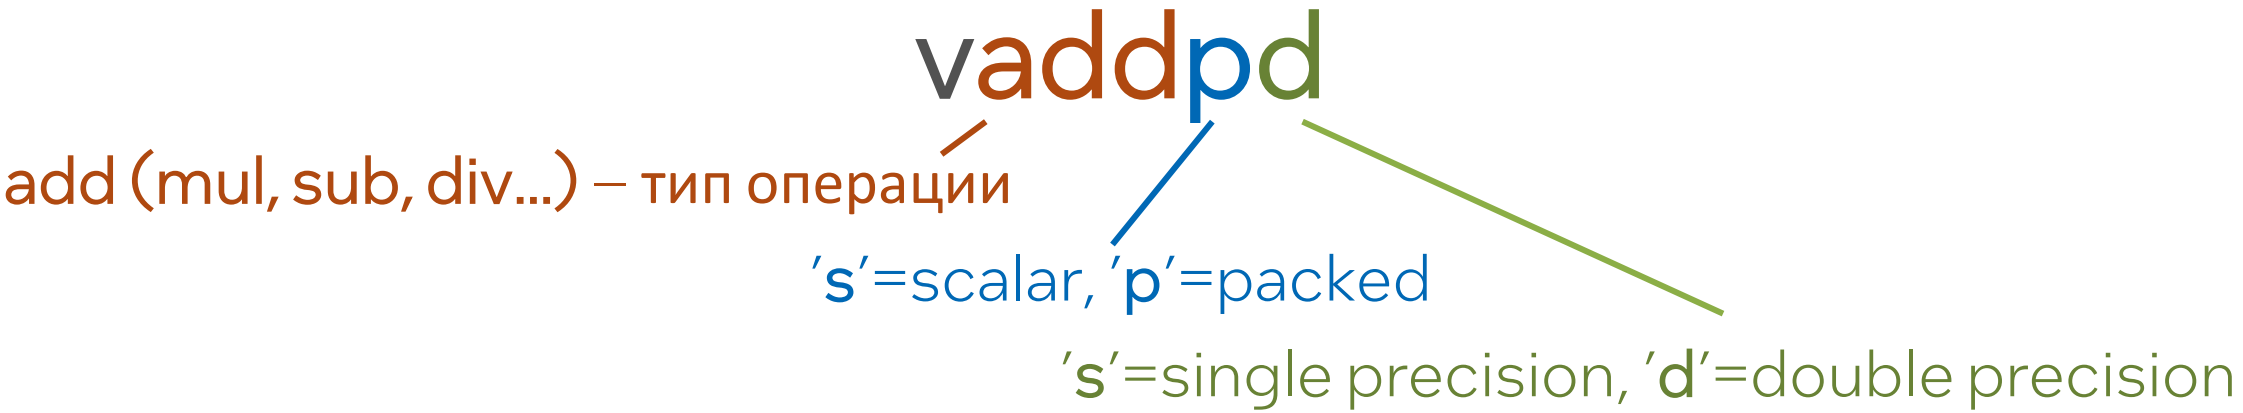

Часть 3. Векторизация, её диагностика и улучшение

3.1. Включение авто-векторизации в C++, Fortran, C#, Python

3.2. Как писать код для векторизации. Примеры

3.3. Инструменты для диагностики векторизации

3.1. Включение векторизации / C++, Fortran

Доступно во всех современных компиляторах

- Ключи компиляции для векторизации на примере Intel® Compiler
  - `-O2, -O3` – высокие уровни оптимизации
  - `-fopenmp` – для переносимой векторизации через стандарт OpenMP 4.0 и выше
  - `-qvec-report=5` – для получения отчётов о векторизации
  - `-fp-model, -fimf-precision` – для настройки точности вычислений и математических функций

- Директивы для компилятора добавляют в код для ручной векторизации
  - `#pragma vector`
  - `#pragma omp simd`

3.1. Включение векторизации / C#

- Использовать .NET Core 3.0 и выше, где поддерживаются стандарты работы с SIMD
- Включить пакет System.Numerics
- Использовать типы данных Vector, Vector2, Vector3, Matrix3x2, Matrix4x4…

- Пример кода

```
using System.Numerics;

var lanes = Vector<int>.Count;
float[] arr = new  float[1_200_000];
Array.Fill<float>( arr, 23.74f );
var v8sum = new Vector<float>();

for( int i = 0; i < arr.Length; i+=lanes )
{
    var v8temp = new Vector<float>( arr, i );
    v8sum += v8temp;
}
```

Материалы и пример кода из статьи
Adrian Jurczak
"SIMD usage in C++, C# and Rust"

3.1. Включение векторизации / Python

- Использовать оптимизированные библиотеки numpy, scipy, scikit-learn или полностью оптимизированную сборку Python, например Intel® Distribution for Python*

- Применять рекомендованные паттерны программирования:
  - избегать for-циклов в Python
  - использовать numpy arrays, broadcasting

- Для трудоёмких кодов задействовать библиотеки с native-частью:
  - Intel® DAAL, OpenCV
  - В ML-фреймворках проверять подключение оптимизированных backend-реализаций

3.2. Способы векторизации. Как писать код

Обсудим в этой лекции

1. Использовать высокопроизводительные библиотеки, эффективно включающие векторные инструкции
2. Написать программу на C/C++ или Fortran и использовать авто-векторизацию современных компиляторов
3. Добавлять специальные ключи и директивы компилятора (подсказки)
4. Применять особые типы данных, дружественные векторизации вроде Intel® SIMD Data Layout Templates
5. Использовать классы интринсиков для SIMD и функции-интринсики
6. Реализовать векторизацию на ассемблере

3.2. Как писать код. Векторизованные библиотеки

- Для математики в C++, Fortran: Intel® MKL, OpenBLAS, BLIS
- Другие оптимизированные библиотеки по типам операций для физики, медиа-кодов fftw, OpenCV
- Для точечного использования математических функций sin(), log(), exp() обращать внимание на LibM, SVML, VML

- *Сложности:*
  - Не все нужные алгоритмы реализованы в библиотеке
  - Реализация в библиотеке, не всегда оптимальна для конкретной задачи
  - Сложности интеграции, поддержки, миграции на другие платформы

3.2. Как писать код. Требования к векторизуемым циклам

- Фиксированное количество итераций
  - Количество итераций должно быть известно до начала цикла
  - Не следует выходить по условию (ранний выход из цикла break)
- Нежелательно вызывать функции
  - Допустимы короткие встраиваемые/inlined-функции
  - Или математические функции с векторной реализацией pow(), sqrt(), sin()…
- Желательно иметь один путь прохождения цикла (single control flow)
  - Редкие условия if() поддерживают векторизацию, нужны проверки или вынос условий за цикл
  - Без switch()-конструкций
- Минимальные зависимости по данным
- Необходим однородный доступ к памяти, загрузка данных, лежащих последовательно либо с одинаковым шагом
- Не следует смешивать объекты разных типов данных в выражениях

3.2. Как писать код. Используем C/C++ или Fortran в сочетании с оптимизирующим компилятором

Ключи компиляции для векторизации:

```
icc -g -O3 -fopenmp -qvec-report=5 example.cpp
```

Директивы для ручной векторизации OpenMP

- #pragma omp simd – объявление simd-цикла и определение деталей способа векторизации
- #pragma omp declare simd – объявление simd-функции для использования внутри simd-циклов

Директивы для ручной векторизации в Intel® Compiler

- #pragma ivdep - “игнорировать” зависимости по данных для векторов
- #pragma vector [always/aligned/nontemporal]– требует векторизовать цикл в зависимости от поданного следующего аргумента
- #pragma omp simd – поддерживается стантарт OpenMP

3.2. Как писать код. Используем C/C++ или Fortran в сочетании с оптимизирующим компилятором

Пример 1. Запрос компилятору векторизовать цикл, игнорируя зависимости, и с выровненными инструкциями

```
#pragma simd
#pragma vector aligned
  for (i=0; i<n; i++)
    a[i] = a[i] * c;
```

Пример 2. Сложный поток управления, авто-векторизация невозможна

```
for (int i=0; i<len; i++)
{
  if (x[i] == 42) break;
  y[i] = x[i];
}
```



```
int m=len;
for (int i=0; i<len; i++)
  if (x[i] == 42) {
    m = i;
    break;
  }
// Векторизация второго цикла теперь возможна
for (int i=0; i<m; i++)
  y[i] = x[i];
```

Пример 3:

```
// Сложный паттерн доступа к данным.
// Невыгоден для авто-векторизации
// и обычно требует изменения
// структуры данных для векторизации.

for (int i = 0; i < len; i++)
{
  b[a[i]] = x;
}
```

3.2. Как писать код. Пример векторизации на C++. Вынос вычисления константы за пределы цикла

Не векторизуемый цикл

```
for (int i = 0; i < len; i++)
{
  y[i] = x[i] * exp(sqrt(len/2.));
}
```

Векторизация возможна

```
double alpha = exp(sqrt(len/2.));
for (int i = 0; i < len; i++)
{
  y[i] = x[i] * alpha;
}
```

3.2. Как писать код. Пример зависимости по данным (loop-carried dependency)

Векторизация меняет порядок исполнения итераций цикла по сравнению с последовательным исполнением.

Компилятор векторизует, если может доказать, что векторизация будет корректной.

Программисту надо следить за независимостью итераций цикла, иначе при форсировании векторизации возможны «падения» программы и некорректные результаты

Прямая зависимость Write After Read (WAR) векторизуется

```
for (int i=0; i<len; i++)
  a[i] = a[i+1] + b[i];
```

Обратная зависимость Read after write (RAW) **не векторизуется**

```
for (int i=1; i<N; i++)
  a[i] = a[i-1] + b[i];
```

Полезны автоматические инструменты определения зависимостей, такие как Intel® Advisor

3.2. Как писать код. Пример оптимизации Memory Access Pattern

Внутренний цикл векторизуется, но шаблон доступа к данным Memory Access Pattern можно оптимизировать

```
for (int x = 0; x < SIZE; x++)
{// Print statements on x-axis prevent loop interchange
  cout << "some diagnostic prints" << x << "\n";
  for (int y = 0; y < SIZE; y++)
        results[y][x] = (tableA[y][x]/tableB[y][x]) - ((double)500.0*atan(tableB[y][x]));
}
```

Vectorized Loops				Instruction Set Analysis
Vector ...	Efficiency	Gain ...	VL ..	Traits
				Divisions; FMA
AVX512	**89%**	**3.56x**	**4**	**Divisions; FMA; Inserts; Scatters**

Диагностика неоптимизированного цикла с помощью Intel® Advisor

Перестановка циклов и улучшение Memory Access Pattern,
но с изменением логики программы

```
for (int y = 0; y < SIZE; y++)
{
  for (int x = 0; x < SIZE; x++)
  {
        results[y][x] = (tableA[y][x] / tableB[y][x]) - ((double) 500.0 * atan(tableB[y][x]));
  }
}
```

Vectorized Loops				Instruction Set Analysis
Vector ...	Efficiency	Gain E...	VL (...	Traits
AVX2	100%	4.85x	4	Divisions; FMA
				Divisions; FMA
AVX2	**100%**	**4.85x**	**4**	**Divisions; FMA**

Диагностика оптимизированного цикла с помощью Intel® Advisor

3.2. Векторизация. Интринсики и ассемблер

- Большой контроль над логикой исполнения
- Сложность разработки: нужно хорошо знать систему команд и особенности архитектуры, а также иметь опыт низкоуровневого программирования
- Трудности с переносимостью кода на другие программно-аппаратные платформы

- Ресурсы для изучения:
  - Intel® Intrinsics Guide
  - Improving performance with SIMD intrinsics in three use cases
  - Software optimization resources by Agner Fog

```
22  #if defined(USE_AVX512)
23
24      // Favor using AVX512 if available.
25      static float
26      L2SqrSIMD16Ext(const void *pVect1v, const void *pVect2v, const void *qty_ptr) {
27          float *pVect1 = (float *) pVect1v;
28          float *pVect2 = (float *) pVect2v;
29          size_t qty = *((size_t *) qty_ptr);
30          float PORTABLE_ALIGN64 TmpRes[16];
31          size_t qty16 = qty >> 4;
32
33          const float *pEnd1 = pVect1 + (qty16 << 4);
34
35          __m512 diff, v1, v2;
36          __m512 sum = _mm512_set1_ps(0);
37
38          while (pVect1 < pEnd1) {
39              v1 = _mm512_loadu_ps(pVect1);
40              pVect1 += 16;
41              v2 = _mm512_loadu_ps(pVect2);
42              pVect2 += 16;
43              diff = _mm512_sub_ps(v1, v2);
44              // sum = _mm512_fmadd_ps(diff, diff, sum);
45              sum = _mm512_add_ps(sum, _mm512_mul_ps(diff, diff));
46          }
47
48          _mm512_store_ps(TmpRes, sum);
49          float res = TmpRes[0] + TmpRes[1] + TmpRes[2] + TmpRes[3] + TmpRes[4] + TmpRes[5] + TmpRes[6] +
50                  TmpRes[7] + TmpRes[8] + TmpRes[9] + TmpRes[10] + TmpRes[11] + TmpRes[12] +
51                  TmpRes[13] + TmpRes[14] + TmpRes[15];
52
53          return (res);
54  }
```

Пример intrinsics: функция поиска расстояния между векторами из Hnswlib - fast approximate nearest neighbor search https://github.com/nmslib/hnswlib

3.2. Векторизация. Пример векторизованного цикла и его ассемблерного кода

```
// Исходный цикл с вычислениями и без зависимостей
for (i = 1; i <= N; ++i__)
{
    result[++k-1] = a[i+j*t]+b[i+j*s]*c[i+j*p];
}
```

```
// Сгенерированный ассемблер с векторными инструкциями AVX2
0x418435            Block 1: 12500000
0x418435    943     vmovups ymm3, ymmword ptr [rdi+0x4]
0x41843a    942     add rdi, 0x20
0x41843e    944     vmovups ymm2, ymmword ptr [rbx+0x4]
0x418443    944     vfmadd213ps ymm3, ymm2, ymmword ptr [r12+0x4]
0x41844a    942     add r12, 0x20
0x41844e    943     vmovntps ymmword ptr [r14+r13*4+0x763c00], ymm3
0x418458    942     add r13, 0x8
0x41845c    942     add rbx, 0x20
0x418460    942     cmp r13, rsi
0x418463    942     jb 0x418435 <Block 1>
```

3.3. Диагностика векторизации / Отчёты компилятора

- Получить отчёт компилятора о векторизации, добавив ключи компиляции
  - ICC ключи –qvec-report=5 (число – уровень детализации отчёта)
  - GCC Ключи -fopt-info-vec
  - Microsoft* /Qvec-report
- Пример отчёта:

```
LOOP BEGIN at D:\work_eantakov\apps\some_example.f
    remark #15389: vectorization support: reference AA has unaligned access
    remark #15389: vectorization support: reference A has unaligned access
    remark #15381: vectorization support: unaligned access used inside loop
body
    remark #15399: vectorization support: unroll factor set to 2
    remark #15300: LOOP WAS VECTORIZED
    remark #15450: unmasked unaligned unit stride loads: 2
```

3.3. Диагностика векторизации / Отчёты компилятора

Пример отчёта о невекторизованных циклах

```
some_example.optrpt:

LOOP BEGIN at D:\work_eantakov\apps\LCD\loops90.f(146,7)
   remark #15382: vectorization support:
      call to function calculate() cannot be vectorized
   remark #15344:
      loop was not vectorized: vector dependence prevents vectorization
   remark #15346:
      vector dependence: assumed OUTPUT dependence between A line 146 and A
line 147
   remark #15521:
      loop was not vectorized: explicitly compute the iteration count before
executing the loop or try using canonical loop form
```

3.3. Диагностика векторизации / Инструмент анализа и рекомендаций Intel® Advisor

Фокусировка на «тяжёлых» циклах

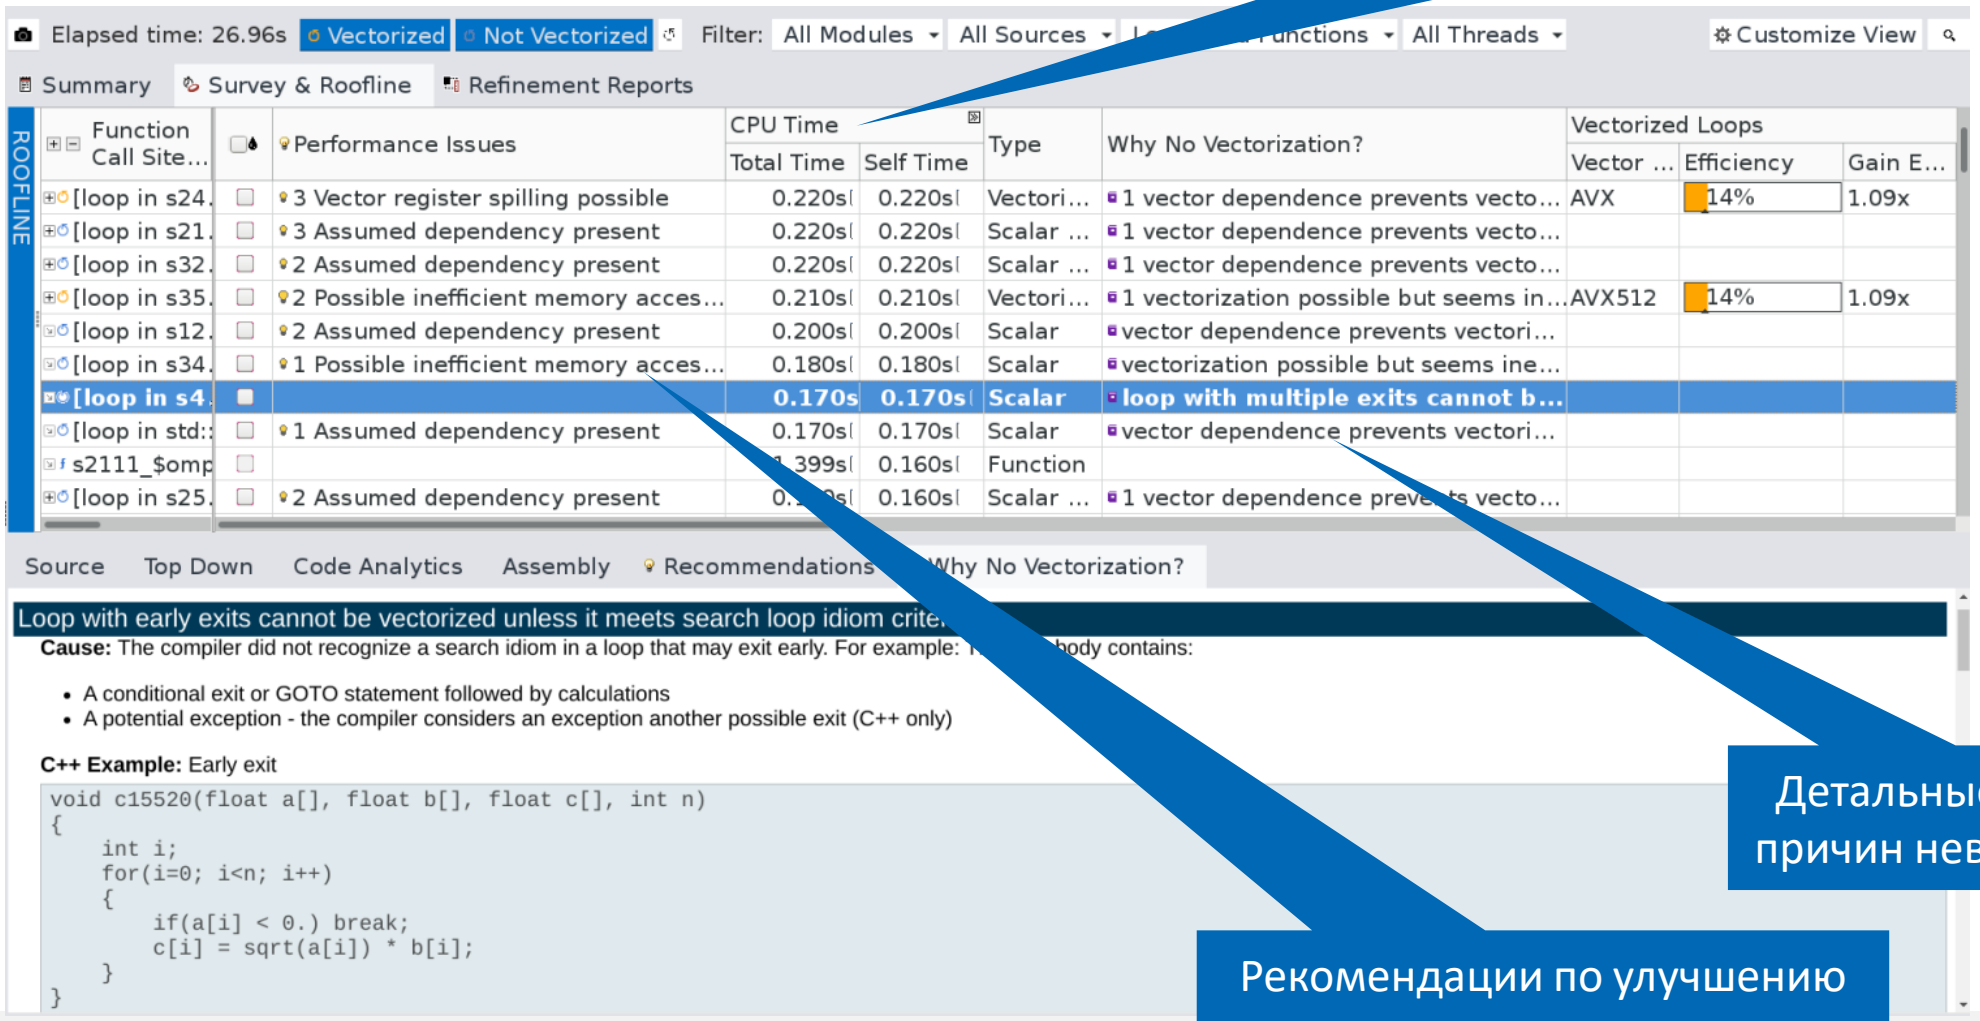

Детальные пояснения причин невекторизации

Рекомендации по улучшению производительности

3.3. Диагностика векторизации / Инструмент анализа и рекомендаций Intel® Advisor

Диагностика причин неэффективной векторизации

Подробности о типах данных и операциях

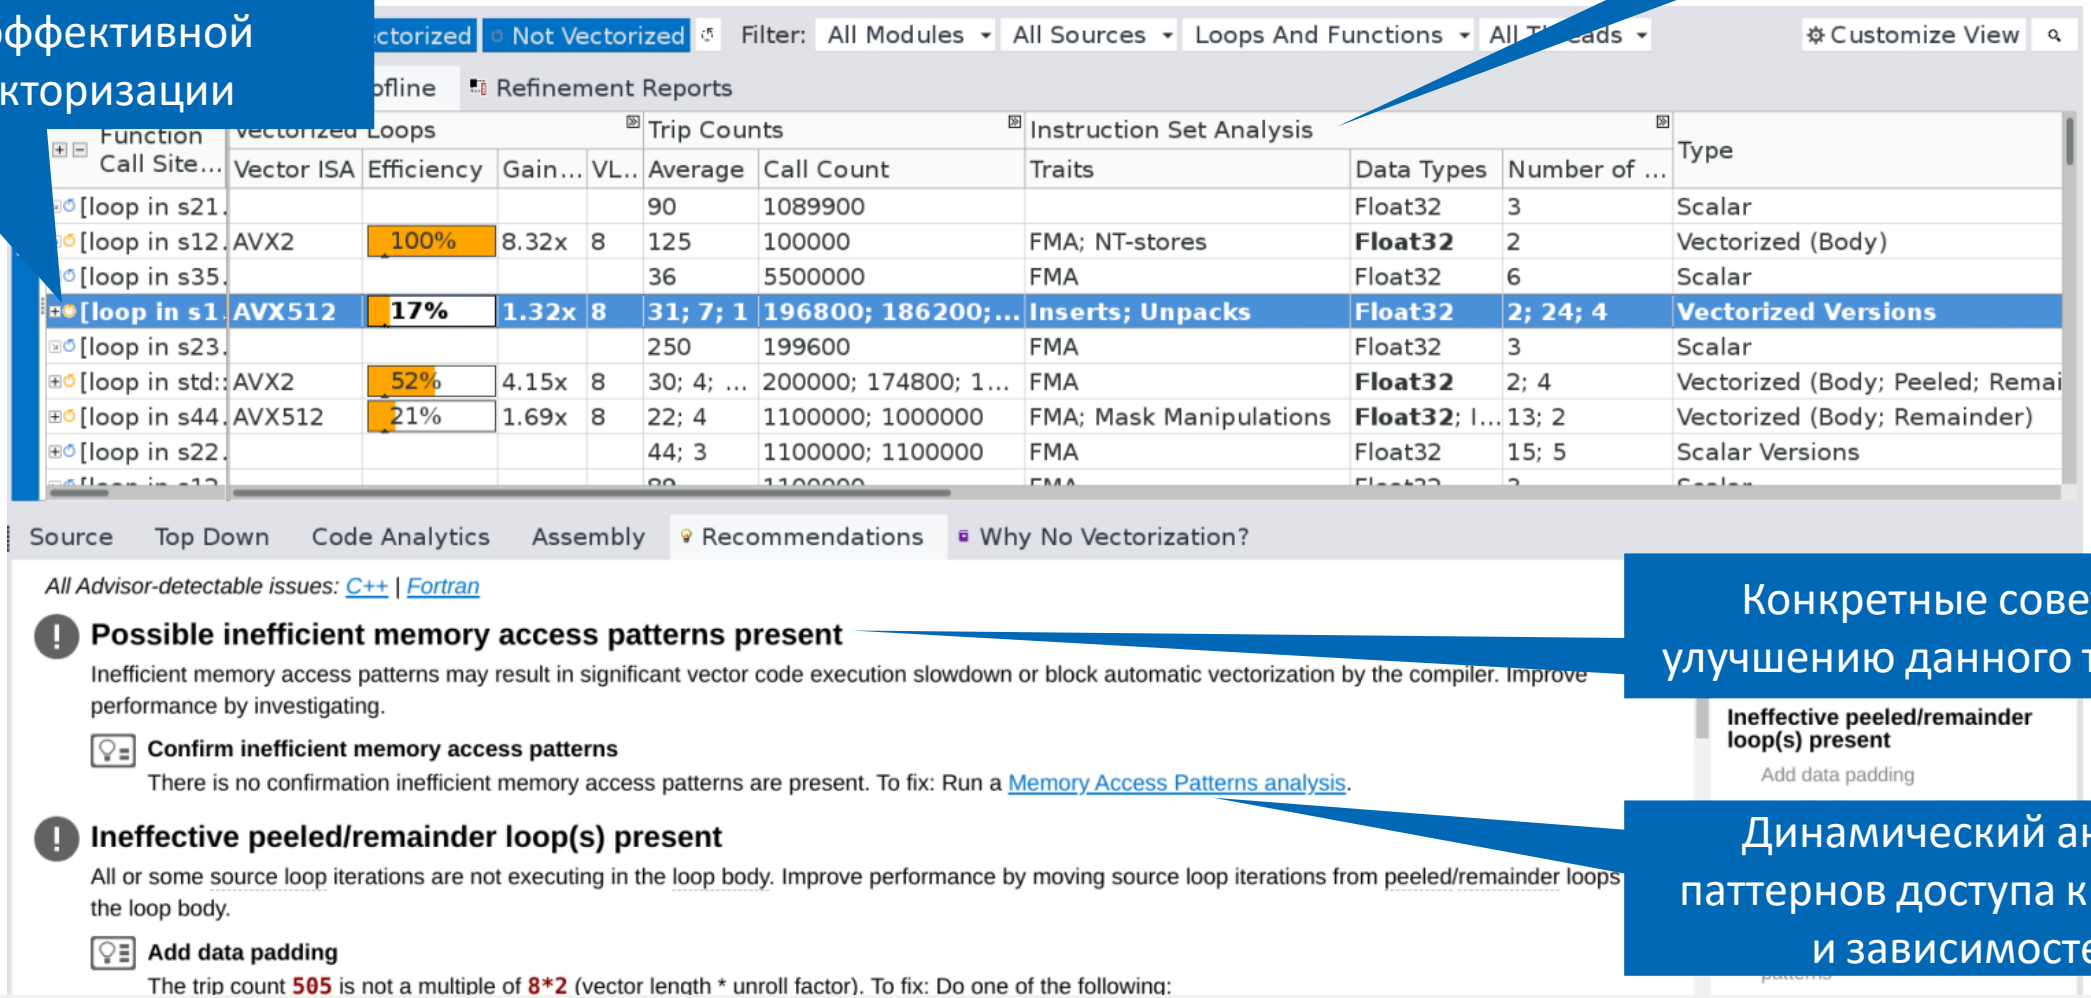

Конкретные советы по улучшению данного типа кода

Динамический анализ паттернов доступа к данным и зависимостей